

LABORATORIUM NAUKI O DANYCH

Data wykonania ćwiczenia:	21.01.2026
Rok studiów:	1
Semestr:	2
Grupa studencka:	2A
Grupa laboratoryjna:	SZI

Ćwiczenie nr	8
--------------	----------

Temat: Zaawansowane techniki analizy skupień: praktyczne ćwiczenia

Osoby wykonujące ćwiczenia:

1. Jakub Jurzak

Katedra Informatyki i Automatyki

1. Celem ćwiczenia było zapoznanie się z metodami analizy skupień oraz ich zastosowanie do danych rzeczywistych. W ramach zadania przeprowadzono grupowanie danych z wykorzystaniem algorytmów **K-means**, **DBSCAN** oraz **hierarchicznej analizy skupień**, a następnie porównano uzyskane wyniki przy użyciu miar jakości grupowania oraz wizualizacji.

Do analizy wykorzystano rzeczywisty zbiór danych **Parkinson's Telemonitoring**, zawierający dane pochodzące z badań pacjentów chorujących na chorobę Parkinsona. Zbiór składa się z cech opisujących parametry sygnału głosu, takich jak miary jitter, shimmer, HNR, NHR oraz cechy nieliniowe (RPDE, DFA, PPE), a także zmiennych demograficznych (wiek, płeć).

Zmienne kliniczne **motor_UPDRS** oraz **total_UPDRS**, opisujące nasilenie objawów choroby, nie były wykorzystywane w procesie klasteryzacji, lecz posłużyły do późniejszej interpretacji otrzymanych klastrów.

Na etapie wstępnego przetwarzania danych:

- usunięto kolumny identyfikacyjne (subject#) oraz zmienną czasową (test_time),
- wybrano do analizy cechy głosu oraz zmienne age i sex,
- dane zostały przeskalowane z użyciem **StandardScaler**, aby zapewnić porównywalny wpływ wszystkich cech na miary odległości wykorzystywane przez algorytmy grupowania.

```
df = pd.read_csv('parkinsons_updrs.data', sep=',')
print(df.head(10))

cols_to_drop = ["subject#", "test_time", "motor_UPDRS", "total_UPDRS"]
X = df.drop(columns=cols_to_drop)
print(X.columns)

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

print(np.mean(X_scaled[:, 0]))
print(np.std(X_scaled[:, 0]))
```

Algorytm K-means został zastosowany dla różnych wartości liczby klastrów k . W celu doboru optymalnej liczby skupień wykorzystano:


- **metodę łokcia**, analizując zmianę wartości funkcji inercji,
- **wskaźnik silhouette**, oceniający spójność i separację klastrów.

Najwyższą wartość wskaźnika silhouette (0.707) uzyskano dla $k = 2$, co wskazuje na bardzo dobrą jakość grupowania. Dla większych wartości k jakość klasteryzacji znacząco się pogarszała.

```
inertia = []
k_values = range(1, 11)

for k in k_values:
    kmeans = KMeans(n_clusters=k, random_state=2137)
    kmeans.fit(X_scaled)
    inertia.append(kmeans.inertia_)

plt.plot(k_values, inertia, marker='o')
plt.xlabel("Liczba klastrów k")
plt.ylabel("Inertia")
plt.title("Metoda łokcia - K-Means")
plt.show()
```



```
for k in [2,3,4,5]:
    kmeans = KMeans(n_clusters=k, random_state=2137)
    labels = kmeans.fit_predict(X_scaled)
    score = silhouette_score(X_scaled, labels)
    print(f"k={k}, silhouette_score = {score:.3f}")
```

```
k=2, silhouette_score = 0.707
k=3, silhouette_score = 0.293
k=4, silhouette_score = 0.224
k=5, silhouette_score = 0.186
```

Po wyznaczeniu klastrów porównano średnie wartości zmiennych klinicznych **motor_UPDRS** oraz **total_UPDRS** w poszczególnych skupieniach.

Zaobserwowano wyraźne różnice pomiędzy klastrami – jeden z nich charakteryzował się wyższymi wartościami UPDRS, co wskazuje na bardziej zaawansowany przebieg choroby, natomiast drugi obejmował obserwacje o łagodniejszych objawach.

Wyniki te sugerują, że na podstawie cech głosu możliwe jest wyodrębnienie grup pacjentów różniących się nasileniem objawów choroby Parkinsona.


```
kmeans = KMeans(n_clusters=2, random_state=2137)
labels = kmeans.fit_predict(X_scaled)

df["cluster"] = labels

print(df.groupby("cluster")[["motor_UPDRS", "total_UPDRS"]].mean())

plt.figure(figsize=(6, 4))
sns.stripplot(x="cluster", y="total_UPDRS", data=df)
plt.title("total_UPDRS - rozrzut w klastrach")
plt.xlabel("Klaster")
plt.ylabel("total_UPDRS")
plt.tight_layout()
plt.show()
```

	motor_UPDRS	total_UPDRS
cluster		
0	23.559696	31.001261
1	21.210664	28.944006



Algorytm DBSCAN został przetestowany dla różnych wartości parametrów `eps` oraz `min_samples`. W zależności od doboru parametrów algorytm wykrywał od kilku do kilkudziesięciu klastrów oraz znaczną liczbę punktów uznanych za szum.

W żadnym z testowanych przypadków nie uzyskano stabilnej struktury skupień ani możliwości wiarygodnego obliczenia wskaźnika `silhouette`. Oznacza to, że w analizowanej przestrzeni cech dane nie tworzą wyraźnych klastrów gęstościowych.

```
eps=0.5, min_samples=5, clusters=43, (brak silhouette)
eps=1.0, min_samples=5, clusters=15, (brak silhouette)
eps=1.5, min_samples=5, clusters=8, (brak silhouette)
eps=1.0, min_samples=10, clusters=9, (brak silhouette)
```

Wnioski:

Na podstawie przeprowadzonej analizy stwierdzono, że algorytm K-means pozwala na skuteczne grupowanie danych z zakresu telemonitoringu choroby Parkinsona. Otrzymane klastry różniły się istotnie poziomem nasilenia objawów choroby, mimo że zmienne kliniczne nie były wykorzystywane w procesie grupowania. Metoda DBSCAN nie wykazała użyteczności dla tego zbioru danych, co wskazuje na brak klastrów gęstościowych w analizowanej przestrzeni cech.