

LABORATORIUM NAUKI O DANYCH

Data wykonania ćwiczenia:	10.12.2025
Rok studiów:	1
Semestr:	2
Grupa studencka:	2A
Grupa laboratoryjna:	SZI

Ćwiczenie nr

7

Temat: Praktyczne zastosowanie rekurencyjnych sieci neuronowych (RNN) do analizy szeregów czasowych

Osoby wykonujące ćwiczenia:

1. Jakub Jurzak

Katedra Informatyki i Automatyki

1. Celem ćwiczenia było zapoznanie się z praktycznym zastosowaniem rekurencyjnych sieci neuronowych typu **LSTM (Long Short-Term Memory)** do analizy danych sekwencyjnych. W ramach wariantu 14 zrealizowano trzy zadania:

- a) prognozowanie zapotrzebowania na energię w budynku,
- b) wykrywanie anomalii w zużyciu prądu,
- c) rozpoznawanie wzorców zużycia energii przez różne urządzenia.

Do realizacji zadań wykorzystano dane syntetyczne oraz bibliotekę **TensorFlow/Keras** w języku Python, zgodnie z instrukcją laboratoryjną

Do realizacji zadania użyto:

- języka **Python**,
- bibliotek: NumPy, Matplotlib, Scikit-learn oraz TensorFlow (Keras),
- sieci neuronowych typu **LSTM**.

Dane zostały poddane normalizacji przy użyciu **MinMaxScaler**.

Prognozowanie zapotrzebowania na energię

Dane wejściowe wygenerowano jako zaszumiony sygnał sinusoidalny, symulujący cykliczne zużycie energii. Utworzono sekwencje czasowe o długości 10 próbek. Model LSTM składał się z jednej warstwy LSTM (100 neuronów) oraz warstwy wyjściowej Dense(1).

Uzyskane wyniki pokazują dobre dopasowanie wartości prognozowanych do rzeczywistych, co potwierdza skuteczność modelu w prognozowaniu zapotrzebowania na energię.

Wykrywanie anomalii w zużyciu prądu

W kolejnym etapie przeprowadzono detekcję anomalii w danych energetycznych. Dane zawierały próbki normalne oraz anomalie w postaci nagłych wzrostów sygnału. Zastosowano model LSTM z wyjściem sigmoid, uczony z wykorzystaniem funkcji straty binary cross-entropy.

Model osiągnął wysoką dokładność klasyfikacji, skutecznie rozróżniając dane normalne od anomalii.

Rozpoznawanie wzorców zużycia energii


W trzecim zadaniu przeprowadzono klasyfikację trzech różnych wzorców zużycia energii, odpowiadających różnym typom urządzeń. Zastosowano sieć LSTM z warstwą wyjściową softmax. Model poprawnie rozpoznawał poszczególne klasy wzorców czasowych.

Wnioski

Na podstawie przeprowadzonych eksperymentów stwierdzono, że:

- sieci LSTM są skuteczne w analizie szeregów czasowych,
- umożliwiają dokładne prognozowanie zapotrzebowania na energię,
- dobrze sprawdzają się w wykrywaniu anomalii oraz klasyfikacji wzorców zużycia energii.

Ćwiczenie potwierdziło przydatność rekurencyjnych sieci neuronowych w analizie danych energetycznych.



Wniosek:

Sieć LSTM skutecznie nadaje się do prognozowania zapotrzebowania na energię w budynku.